

Xây dựng Trợ lý Dữ liệu Tài chính AI (AI Financial Data Assistant)

Từ Tiền xử lý, Truy xuất Bảng biểu đến Phân tích Suy luận của LLMs

Presenter: Nguyễn Hoàng Trung, Nguyễn Tấn Minh

VNU University of Science and Technology
Japan Advanced Institute of Science and Technology

August, 12 2026

Table of contents

Tổng quan bài toán End-to-End Financial QA

Quy trình Tiền xử lý Dữ liệu

Truy xuất Bảng biểu

Tabular Financial QA & Reasoning

Tổng quan bài toán End-to-End Financial QA

Bài toán Financial Question Answering


- ▶ Đầu vào là một **câu hỏi tài chính bằng ngôn ngữ tự nhiên**.
- ▶ Nguồn dữ liệu là một tập lớn các **báo cáo tài chính**.
- ▶ Hệ thống cần:
 1. Tìm đúng báo cáo.
 2. Tìm đúng bảng.
 3. Tìm đúng dữ liệu cần thiết.
 4. Thực hiện tính toán để trả lời câu hỏi.

Ví dụ

Doanh thu của công ty X năm 2023 tăng bao nhiêu phần trăm so với năm 2022?


Tại sao lại chọn Text-to-Pandas thay vì Text-to-SQL?

Text-to-SQL




- ▶ Phù hợp với dữ liệu đã có **schema rõ ràng**.
- ▶ Mạnh cho **filter, join, aggregation**.

Text-to-Pandas




- ▶ Làm việc trực tiếp với **bảng OCR đã chuẩn hóa**.
- ▶ Linh hoạt với **schema không đồng nhất**.

End-to-End Financial QA




Khác biệt với Financial QA truyền thống

Traditional Financial QA



End-to-End Financial QA




Vấn đề cốt lõi

Trước khi yêu cầu mô hình tính toán chính xác, hệ thống phải tìm được đúng dữ liệu.

Tiền xử lý Dữ liệu

Nguồn gốc dữ liệu và Thách thức ban đầu

- ▶ Nguồn dữ liệu: ViFinQA được trích xuất từ tập dữ liệu báo cáo tài chính của TiniX Vietnam.
- ▶ Các báo cáo PDF được xử lý bằng OCR để chuyển thành dữ liệu văn bản.
- ▶ Trong văn bản thu được, các nội dung bảng biểu được lưu giữ dưới dạng các khối mã HTML `<table>`.



Ví dụ dữ liệu sau OCR


Financial report

BAO CAO TAI CHINH HOP NHAT
Nam 2023

```
<table>
<tr>
<td>Chi tieu</td>
<td>2023</td>
<td>2022</td>
</tr>

<tr>
<td>Tong tai san</td>
<td>15230000</td>
<td>12410000</td>
</tr>
</table>
```

Từ TXT sang các bảng có cấu trúc



Các thách thức ban đầu từ OCR

Công nghệ OCR thường tạo ra nhiều lỗi cấu trúc nghiêm trọng:

- ▶ **Merged cells:** Các ô bị gộp dòng hoặc gộp cột (*rowspan*, *colspan*).
- ▶ **Misaligned rows:** Các dòng bị lệch hàng, không thẳng lối.
- ▶ **Irregular spans:** Tiêu đề bị lặp lại hoặc phạm vi tiêu đề không đều.

Hệ quả

Những lỗi này khiến cho các giá trị số tài chính dễ bị phân tách hoặc gán nhầm với các nhãn dòng/cột mô tả tương ứng của chúng.

Bước A: Trích xuất bảng (Table Extraction)

- ▶ Hệ thống tự động quét và cô lập từng khối mã HTML `<table>` riêng lẻ từ tệp văn bản báo cáo tài chính thô.

Tệp văn bản gốc → Các khối HTML `<table>`

Bước B: Làm sạch bảng biểu (Table Cleaning)

Mục tiêu: Biến đổi các cấu trúc HTML phức tạp thành một lưới ô dữ liệu hình chữ nhật chuẩn hóa.

- ▶ **Loại bỏ thẻ HTML (Remove HTML tags):** Loại bỏ hoàn toàn các thẻ HTML định dạng để lấy dữ liệu văn bản thô bên trong.
- ▶ **Chuẩn hóa khoảng trắng (Normalize whitespace):** Chuẩn hóa khoảng trắng và xử lý các thực thể đặc biệt (như).
- ▶ **Mở rộng ô gộp (Expand rowspan/colspan):** Nhận diện và tự động mở rộng các ô gộp dòng/cột thành các ô riêng biệt để lấp đầy mạng lưới hai chiều.
- ▶ **Căn chỉnh độ rộng (Align rows):** Đảm bảo cấu trúc lưới của bảng đồng đều về số cột ở mọi hàng.

Bước C: Chuẩn hóa bảng biểu

Mục tiêu: Giữ vững ngữ cảnh tài chính và thứ bậc cấu trúc của bảng.

- ▶ **Làm phẳng tiêu đề (Flatten multi-row headers):** Các tiêu đề nhiều cấp phức tạp được "làm phẳng" thành các đường dẫn phân tách bằng dấu gạch dưới (VD: Tổng_cộng_31/12/2022). Các đơn vị đo lường được nhận diện và giữ lại.
- ▶ **Thêm ngữ cảnh nhóm (Add group context):** Các tiêu đề mục lớn (section headings) sẽ được tự động lan truyền dưới dạng tiền tố cho các nhãn danh mục con ở các dòng tiếp theo để bảo toàn cấu trúc phân cấp (financial hierarchies).
- ▶ **Loại bỏ trùng lặp (Remove duplicates):** Làm sạch các dữ liệu dư thừa phát sinh từ việc mở rộng các ô đã gộp trước đó.

Chuẩn hóa bảng (Minh họa)

Raw Table		
	2023	2022
Doanh thu	100000	80000
Lợi nhuận	15000	12000

Normalized Table		
Chỉ tiêu	2023	2022
Doanh thu	100000	80000
Lợi nhuận	15000	12000

Mục tiêu: tạo bảng mà máy có thể truy vấn và tính toán ổn định.

Kết quả đầu ra của Tiền xử lý (Outputs)

Dữ liệu đầu ra được chia làm hai phần đồng bộ hóa:

1. **Các tệp CSV chuẩn hóa:** Mỗi bảng biểu sau khi làm sạch được lưu thành một tệp CSV riêng lẻ (VD: `table_1.csv`, `table_2.csv`).
2. **Các tệp Văn bản (Text Files):** Trong văn bản báo cáo gốc, hệ thống thay thế khối HTML bằng một **liên kết đồng bộ (synchronized link)** trỏ trực tiếp đến tệp CSV tương ứng.

Ý nghĩa

Tệp văn bản chỉ còn giữ lại ngữ cảnh xung quanh và siêu dữ liệu (metadata) của bảng. Quy trình này giúp các LLM dễ dàng đọc dữ liệu chính xác thông qua thư viện Pandas (DataFrame) mà không bị ảnh hưởng bởi lỗi cấu trúc của OCR.

Bảng thô chưa đủ

Giả sử chúng ta có:

table_01.csv

table_02.csv

table_03.csv

Từ nội dung bảng, hệ thống có thể chưa biết:

- ▶ Bảng thuộc công ty nào?
- ▶ Báo cáo năm nào?
- ▶ Báo cáo hợp nhất hay riêng?
- ▶ Đây là loại báo cáo gì?
- ▶ Đơn vị của số liệu là gì?

Metadata cho mỗi bảng

Mỗi bảng được liên kết với metadata:

Field	Value
Company	VCB
Year	2023
Report Type	Consolidated
Statement	Balance Sheet
Table ID	VCB-2023-Table-17
Unit	Million VND

Ý nghĩa

Table extraction cung cấp **structure**, trong khi metadata cung cấp **context**.

Truy xuất Bảng biểu

Tại sao cần Retrieval?

- ▶ Một corpus tài chính có thể chứa hàng chục hoặc hàng trăm nghìn bảng.
- ▶ Không thể đưa toàn bộ corpus vào context của LLM.
- ▶ Với mỗi câu hỏi, cần tìm ra một tập nhỏ các bảng có khả năng chứa dữ liệu cần thiết.

146K Tables




Retriever



Top- K Tables

Table Retrieval Pipeline



Lexical Retrieval: BM25

- ▶ BM25 dựa trên mức độ khớp giữa từ khóa của câu hỏi và nội dung bảng.
- ▶ Phù hợp khi câu hỏi và bảng sử dụng cùng thuật ngữ.

Question


Tổng tài sản của VCB năm 2023 là bao nhiêu?

Table

Tổng tài sản	2023	2022
--------------	------	------


Ưu điểm: đơn giản, nhanh và hiệu quả với exact matching.

Dense Retrieval



- Dense retrieval có thể tìm các bảng có ý nghĩa tương tự ngay cả khi từ ngữ không hoàn toàn giống nhau.

Retriever và Reranker



Vai trò

Retriever: ưu tiên tốc độ và recall.

Reranker: ưu tiên độ chính xác khi sắp xếp các ứng viên.

Kết quả Table Retrieval trên ViFinQA

Method	Recall@10
BM25	47.41%
BGE-M3	53.05%
Qwen3-Embedding-4B	63.90%
Qwen3-Embedding-8B	67.48%
Qwen3-Embedding-4B + Reranker	80.19%
Qwen3-Embedding-8B + Reranker	80.80%

Observation

Reranking cải thiện đáng kể retrieval, nhưng hệ thống tốt nhất vẫn bỏ sót khoảng 19.2% các gold tables.

Tại sao Recall quan trọng?


Giả sử một câu hỏi cần bốn bảng:

Required Table		Retrieved?
Table A	→	Yes
Table B	→	Yes
Table C	→	Yes
Table D	→	No


Multi-table QA

Chỉ cần thiếu một bảng cần thiết, các bước reasoning tiếp theo có thể không thực hiện được.

Từ dữ liệu thô đến Evidence



Bước tiếp theo



Câu hỏi tiếp theo

Khi đã tìm được đúng các bảng, làm thế nào để LLM suy luận và tính toán chính xác trên những bảng này?

Tabular Financial QA & Reasoning

Khâu Suy luận Tài chính (Tabular Financial Reasoning)

- ▶ **Đầu vào khâu QA:** Câu hỏi tự nhiên + Tập K bảng CSV đã được trích xuất từ retriever.
- ▶ **Mục tiêu:** Xác định ô dữ liệu chính xác, thực hiện các phép tính tài chính và trả về đáp án số duy nhất.

Thách thức đặc thù của Báo cáo Tài chính Việt Nam

- ▶ **Định dạng số địa phương:** Dấu chấm '.' làm phân cách hàng nghìn ('15.230.000'), dấu phẩy ',' làm số thập phân ('12,5%').
- ▶ **Giá trị âm dạng đóng ngoặc:** '(500.000)' tương đương với '-500.000'.
- ▶ **Đơn vị đo lường biến đổi:** Triệu VNĐ, Tỷ VNĐ, USD thay đổi tùy theo từng bảng.
- ▶ **Chỉ tiêu phân cấp & Thiếu nhãn cột:** Nhãn chỉ tiêu lồng nhau theo thứ bậc kế toán; cột không tên.

Các Cấp độ Phức tạp của Bài toán QA (Difficulty Tiers)

Tập dữ liệu ViFinQA (1,012 câu hỏi) được chia thành 4 cấp độ suy luận:

Level	Count	Mô tả suy luận
Easy	361 (35.7%)	Truy xuất trực tiếp 1 giá trị số từ 1 bảng đơn lẻ.
Medium	235 (23.2%)	Dùng 2 giá trị số + 1 phép tính số học đơn giản (+, -, *, /).
Intermediate	200 (19.8%)	Dùng > 2 giá trị + nhiều phép tính lặp/gom nhóm (Mean, Margin).
Hard	216 (21.3%)	Multi-hop dependent: Kết quả trung gian quyết định bảng/công ty/kỳ báo cáo tiếp theo.

Hai Chiến lược Suy luận: PoT vs. CoT

Program-of-Thought (PoT)

LLM sinh ra đoạn mã Python/Pandas executable → Chạy mã trên môi trường Sandbox → Lấy giá trị gán vào 'result'.

Ưu điểm:

- ▶ Đảm bảo tính toán số học chính xác 100%.
- ▶ Tránh trôi số (drift) khi tính toán dài.

Nhược điểm:

- ▶ Nhạy cảm với lỗi cú pháp code.
- ▶ Đòi hỏi mô hình sinh code mạnh.

Chain-of-Thought (CoT)

LLM tự suy luận các bước bằng ngôn ngữ tự nhiên và đưa ra đáp án số trực tiếp trong văn bản.

Ưu điểm:

- ▶ Linh hoạt, không lo crash môi trường code.
- ▶ Dễ áp dụng cho các mô hình nhỏ.

Nhược điểm:

- ▶ Dễ tính sai số học (arithmetic error).
- ▶ Khó kiểm soát định dạng đầu ra.

Ví dụ Prompting: Chain-of-Thought

Cấu trúc mẫu CoT

Role Instruction: *"You are an assistant for analyzing Vietnamese financial statements... answer with EXACTLY ONE numeric value."*

- ▶ **Output Constraint:** Chỉ trả về duy nhất 1 giá trị số; không chứa đơn vị, ký hiệu hay Markdown.
- ▶ **Data Conventions:** Tự chuyển đổi số thô kiểu VN (. nghìn, , thập phân, () số âm).
- ▶ **Semantic Conventions:** Chênh lệch không hướng → lấy giá trị tuyệt đối không âm; có hướng → giữ nguyên dấu.
- ▶ **Rounding Rule:** Không làm tròn trung gian; chỉ làm tròn kết quả cuối cùng 2 chữ số thập phân.

Ví dụ Trả lời Trực tiếp / CoT

Câu hỏi: Cash balance of Hoa Sen Group on 30/9/2020 (Billion VND)?

1. Tra cứu bảng HSG_2020_consolidated|table_13.
2. Dòng "Tiền và các khoản tương đương tiền" ngày 30/9/2020: "38.446.527.451" VND.
3. Parse định dạng số VN:
"38.446.527.451" -> 38446527451.
4. Đổi sang Tỷ VND & làm tròn 2 chữ số:
 $38446527451 / 1e9 = 38.4465... \rightarrow 38.45$

Answer: 38.45

Ví dụ Prompting: Program-of-Thought

Cấu trúc mẫu PoT

Role Instruction: *You generate Python/pandas code that answers financial questions over Vietnamese financial-statement tables.*

- ▶ **Runtime Contract:** Không import; dùng pd và dict dfs[table_ref] sẵn có.
- ▶ **Data Contract:** Xử lý định dạng số VN (. nghìn, , thập phân, () số âm).
- ▶ **Semantic Rules:** Lấy giá trị tuyệt đối không âm khi tính toán chênh lệch giữa hai giá trị; có hướng → giữ nguyên dấu.
- ▶ **Reliability Rules:** Giữ nguyên tên của hàng và cột, không làm tròn số trung gian, gán đáp án số vào result.

Ví dụ Sinh Mã Pandas

Câu hỏi: Cash balance of Hoa Sen Group on 30/9/2020 (Billion VND)?

```
# Select consolidated evidence table
df = dfs["HSG_2020_consolidated|table_13"]

# Locate row by label & extract raw string
row = df[df.iloc[:,0].str.contains("Tiền mặt")].iloc[0]
raw_val = row["30/9/2020"] # "38.446.527.451"

# Parse VN formatting & convert unit to Billion
val_clean = raw_val.replace(".", "").replace(",", ".")
result = round(float(val_clean) / 1e9, 2) # -> 38.45
```

Thực nghiệm: Đánh giá trên 14 LLMs

Thử nghiệm được thực hiện trên 14 mô hình thuộc 3 nhóm chính:

- ▶ **Commercial Frontiers:** Gemini 3 Flash Preview, DeepSeek-V4-Flash, GPT-5.4 Thinking.
- ▶ **Code-Specialized LLMs:** Qwen3-Coder-480B, Qwen3-Coder-30B, Qwen2.5-Coder series.
- ▶ **General Open-Weight LLMs:** Gemma 4 31B IT, Qwen3 series (235B, 30B, 4B), Granite-4.1-3B, Llama-3.2 (3B, 1B).

Kết quả QA: Oracle Evidence vs. Retrieved Evidence

Answering Setting	Best CoT Accuracy	Best PoT Accuracy
Oracle Evidence (Cung cấp sẵn gold tables)	87.0%	76.0%
Retrieved Evidence ($k = 10$ tables)	64.0%	62.0%
Performance Drop	-23.0%	-14.0%

Nghẽn cổ chai của Hệ thống (The Main Bottleneck)

Khi được cấp đúng bảng (Oracle), LLMs suy luận rất tốt (đạt 87%). Lỗi truy xuất và nhiều bảng ở bước trước làm giảm hơn **20% độ chính xác** end-to-end!

Kết quả QA theo Cấp độ Khó (Difficulty Scaling)

Model	Easy		Medium		Intermediate		Hard	
	PoT	CoT	PoT	CoT	PoT	CoT	PoT	CoT
Gemini 3 Flash	81.4%	75.1%	64.7%	56.6%	55.5%	52.0%	32.9%	28.2%
DeepSeek-V4-Flash	81.7%	83.7%	59.6%	66.4%	53.0%	60.5%	19.0%	30.1%
Gemma 4 31B IT	65.7%	84.5%	53.6%	62.1%	32.0%	62.5%	16.2%	31.9%
Qwen3-Coder-480B	59.0%	28.5%	34.5%	11.5%	34.0%	19.0%	13.4%	1.9%

Nhận xét quan trọng

- ▶ Độ chính xác suy giảm mạnh khi bài toán chuyển từ Easy (84.5%) sang Hard (32.9%).
- ▶ Mô hình chuyên Code (Qwen3-Coder) bị suy giảm nặng trên câu hỏi Hard (<14%), cho thấy phụ thuộc dữ liệu multi-hop đòi hỏi năng lực định vị ngữ cảnh hơn là cú pháp lập trình đơn thuần.

So sánh PoT vs. CoT: Đây là sự lựa chọn tối ưu?

Nhóm mô hình	Mô hình đại diện	PoT Avg	CoT Avg	Δ
Advanced / Frontier	Gemini 3 Flash Preview	62.06%	56.23%	+5.83% (PoT)
	DeepSeek-V4-Flash	57.51%	63.64%	+6.13% (CoT)
	GPT-5.4 Thinking	40.32%	59.88%	+19.56% (CoT)
Code-Specialized	Qwen3-Coder-480B	38.64%	17.00%	+21.64% (PoT)
	Qwen3-Coder-30B	25.59%	11.96%	+13.63% (PoT)
Small LLMs (< 10B)	Qwen3-4B-Instruct	4.64%	11.56%	+6.92% (CoT)
	Qwen2.5-Coder-7B	0.30%	9.49%	+9.19% (CoT)
	Granite-4.1-3B	2.08%	9.09%	+7.01% (CoT)

- **Mô hình Code & Gemini 3 → PoT vượt trội:** Sinh mã Pandas chính xác giúp tăng tới **+21.6%** độ chính xác.
- **Mô hình nhỏ < 10B → crash code:** Tỷ lệ lỗi cú pháp PoT lên đến **99%**.

Phân tích Lỗi

Phân tích chi tiết 430 ca lỗi end-to-end của DeepSeek-V4-Flash (PoT):

Mã lỗi	Loại lỗi	Tỷ lệ (%)
E	Numerical Extraction (Đọc sai ô/dòng/cột số liệu)	54.7%
I	Insufficient Evidence (Retriever thiếu bằng)	34.7%
T	Technical / Syntax (Lỗi crash code/key error)	9.3%
C	Numerical Calculation (Lỗi tính toán số học)	0.9%
F	Formula Application (Đọc sai công thức tài chính)	0.5%

Kết luận cốt lõi

89.3% lỗi đến từ việc trích xuất sai dữ liệu (Extraction) hoặc thiếu bằng (Evidence) Lỗi tính toán số học và lỗi công thức rất hiếm. **LLMs không đốt toán, vấn đề là chọn sai ô số liệu**

Extended Prompting: Model Collaboration (Hợp tác đa Mô hình)

- **Tách biệt vai trò (Role Specialization):** Một mô hình đơn lẻ khó có thể vừa giỏi định vị ngữ cảnh tài chính phức tạp, vừa viết mã Pandas không lỗi cú pháp.


Quy trình Hợp tác đa Mô hình

1. **Planner / Financial Expert (Frontier LLM - GPT-5.4 / Gemini 3):** Phân tích câu hỏi, lập kế hoạch suy luận multi-hop và xác định công thức tài chính.
2. **Coder / Interpreter (Code LLM - Qwen3-Coder):** Nhận kế hoạch và cấu trúc bảng → Sinh mã Pandas chính xác 100% để thực thi trên dữ liệu thô.
3. **Auditor / Verifier (Reviewer LLM - DeepSeek-V4):** Kiểm tra độc lập ô dữ liệu đã trích xuất, đối soát đơn vị (Triệu vs. Tỷ VNĐ) và loại bỏ lỗi hallucination.

Bài học Thực tiễn cho Kỹ sư AI Financial Systems

1. **Cơ chế Cell Grounding là trọng tâm:** Cần thiết kế prompt/schema rõ ràng (tiền tố hàng, cột chỉ tiêu) để tránh việc LLM đọc nhầm dòng giữa các bảng nhiều.
2. **Chiến lược Hybrid linh hoạt:** Dùng PoT cho mô hình Frontier/Code lớn; chuyển sang CoT cho các mô hình nhỏ ($< 10B$) để tránh crash code.
3. **Tiền xử lý định dạng số local:** Chuẩn hóa trước các định dạng số kiểu Việt Nam ('.', ',', '()') trước khi nạp vào DataFrame để giảm lỗi parse dữ liệu.

Tổng kết Khâu QA



Thông điệp chính

Chìa khóa cho Financial Tabular QA không nằm ở khả năng tính toán suông, mà nằm ở **khả năng định vị ô dữ liệu chuẩn xác trong môi trường bảng biểu phức tạp.**

Thank you for your attention!